

CareGuard-VN: Hợp đồng Định danh Thuốc Gắn với Nguồn như một Cổng An toàn Chọn lọc cho Sàng lọc Tương tác Thuốc-Thuốc

Nguyễn Ngọc Thiệp Trịnh Minh Quang
Trường THPT Hai Bà Trưng, Huế, Việt Nam
Tác giả liên hệ: kakangocthien109@gmail.com

Bản nghiên cứu hoàn thiện – Tháng 8 năm 2026

Abstract

Các hệ thống hỗ trợ ra quyết định lâm sàng (CDSS) kiểm tra tương tác thuốc-thuốc (DDI) dựa trên một tiền đề nền tảng nhưng thường bị xem nhẹ trong các mô hình trí tuệ nhân tạo (AI) ứng dụng: *định danh của các thuốc đầu vào được chuyển cho tầng suy luận DDI bắt buộc phải được giải quyết chính xác, gắn chặt với phiên bản nguồn tri thức xác thực và không được phép tồn tại sự mơ hồ*. Khi bài toán chuẩn hóa tên thuốc bị tách rời khỏi quá trình kiểm tra tương tác, các lỗi nhận diện thực thể ở tầng trên sẽ âm thầm lan truyền xuống tầng dưới, tạo ra các kết luận “an toàn” mang tính trấn an giả tạo (*false-reassurance / false-clear*) vô cùng nguy hiểm đối với các phối hợp thuốc tử vong. Trong bài báo này, chúng tôi giới thiệu **CareGuard-VN**, một kiến trúc an toàn lâm sàng chuyển đổi bài toán chuẩn hóa thực thể từ một tác vụ chấm điểm NLP độc lập thành một **Hợp đồng Định danh Thuốc Gắn với Nguồn (Source-Bound Medication Identity, SBMI)** dựa trên khung lý thuyết phân loại chọn lọc Rủi ro-Độ bao phủ của Chow (1970) và Geifman & El-Yaniv (NeurIPS 2017). Theo SBMI, một kết luận DDI mang tính trấn an chỉ được phép phát hành khi và chỉ khi mọi thuốc tham gia đều thỏa mãn các điều kiện thẩm định nguồn nghiêm ngặt có gắn phiên bản; nếu không, hệ thống bắt buộc phải thực thi cơ chế từ chối an toàn (fail-closed) chuyển sang trạng thái yêu cầu làm rõ hoặc xác minh chưa hoàn tất. Chúng tôi phân định ranh giới lý thuyết của SBMI với các mô hình chuẩn hóa độc lập (RxMap, RxEmbed) vốn chỉ tối ưu điểm số chuỗi ký tự, và các bộ xác minh DDI băm bằng chứng (CrossDDI) vốn giả định các cặp thuốc đầu vào đã được chuẩn hóa hoàn hảo. Để đánh giá tính khả thi trong điều kiện vận hành bệnh viện thực tế, chúng tôi thực hiện thử nghiệm lâm sàng đa phương thức đầu cuối sử dụng mô hình thị giác-ngôn ngữ Gemini 3.7 Flash Tiered kết hợp với nhân xác định CareGuard-VN trên $N = 150$ ca bệnh án Việt Nam không đồng nhất (50 đơn thuốc viết tay, 50 tóm tắt ra viện in nhiệt, 50 ảnh bao bì thuốc OTC). CareGuard-VN đạt điểm F1 nhận diện tên thuốc **98,1%** (Độ chính xác 98,4%, Độ thu hồi 97,8%), F1 hàm lượng/liều **96,8%**, Độ nhạy phát hiện DDI nghiêm trọng **99,6%** (Tỷ lệ âm tính giả FNR chỉ **0,40%**), và thực thi **tỷ lệ chặn 100,0% (Fail-Closed)** đối với các khẳng định chưa qua xác thực thông qua rào chắn an toàn FIDES. Cuối cùng, chúng tôi thiết lập giao thức đánh giá ngoài chuẩn hóa trên dữ liệu Cục Quản lý Dược Việt Nam (DAV), RxNorm, DDInter 2.0 và DailyMed với nhánh định danh chuẩn tham chiếu (oracle) nhằm bóc tách triệt để lỗi định danh khỏi giới hạn bao phủ của cơ sở tri thức.

1 Giới thiệu và Động lực Nghiên cứu

Sàng lọc tương tác thuốc-thuốc (DDI) tự động chỉ có giá trị lâm sàng khi hệ thống biết chính xác người bệnh đang sử dụng những hoạt chất nào. Trong thực tế khám chữa

Minh họa lỗi hổng Báo An Toàn Sai trong quy trình CDSS truyền thống:
Đơn thuốc đầu vào: “Plavix 75mg, Aspirin 81mg, Nexium 40mg (Esomeprazole)”
Hệ thống tách rời truyền thống: Chuẩn hóa được Plavix và Aspirin, nhưng nhận diện lỗi hoặc bỏ qua Nexium → Tăng DDI kiểm tra (Plavix, Aspirin) → Báo an toàn → **LỖI NGUY HIỂM**: Bỏ sót tương tác ức chế enzym CYP2C19 giữa Clopidogrel và Esomeprazole (làm giảm hoạt hóa Plavix, tăng nguy cơ huyết khối tắc mạch).
Hợp đồng SBMI CareGuard-VN: Phát hiện ánh xạ Nexium chưa đủ điều kiện xác thực nguồn → Kích hoạt rào chắn Fail-Closed yêu cầu làm rõ → **LOẠI BỎ HOÀN TOÀN BÁO AN TOÀN SAI**.

Figure 1: Cơ chế phát sinh lỗi báo an toàn sai trong hệ thống CDSS truyền thống so với cơ chế rào chắn fail-closed của hợp đồng SBMI trong CareGuard-VN.

bệnh, tên thuốc thể hiện sự biến thiên từ vựng cực kỳ phức tạp: từ tên biệt dược thương mại, tên hoạt chất quốc tế (INN), tên theo danh mục trúng thầu địa phương, dạng bào chế, quy cách hàm lượng cho đến các từ viết tắt, lỗi chính tả và ngôn ngữ tự do của bác sĩ. Mặc dù các hệ thống thuật ngữ như RxNorm và công cụ MedXN đã đặt nền móng cho chuẩn hóa thuốc [1, 2], và các kỹ thuật đối sánh gần đúng đã xử lý biến thể từ vựng từ lâu [3], các tiến bộ AI gần đây đã nâng cao năng lực chuẩn hóa lên một tầm cao mới. Các hệ sinh thái hiện đại như RxMap kết hợp sinh ứng viên xác định với phân tích từ vựng bằng LLM [15], hay RxEmbed ứng dụng biểu diễn vector mật độ cao (dense embeddings) [16] đã đạt độ chính xác chuẩn hóa rất cao. Do đó, bài toán chuẩn hóa tên thuốc đơn thuần là một lĩnh vực nghiên cứu đã trưởng thành [25].

Tương tự, việc phát hiện sự mơ hồ và cơ chế phân loại chọn lọc (selective classification / abstention) cũng đã có nền tảng toán học vững chắc từ nguyên lý đánh đổi sai số-từ chối của Chow (1970) [6] và các nghiên cứu học sâu của Geifman & El-Yaniv [7]. Các hệ thống dự đoán chọn lọc cho phép mô hình từ chối đưa ra kết luận khi chi phí của một dự đoán sai lớn hơn chi phí chuyển ca bệnh cho chuyên gia y tế thẩm định [5]. CareGuard-VN không xem việc phát hiện mơ hồ hay từ chối trả lời là một phát kiến độc lập.

Lỗi hổng an toàn nguy hiểm nhất nằm ở **điểm giao thoa giữa bước chuẩn hóa thực thể và tăng suy luận DDI phía sau**. Các cơ sở dữ liệu DDI (như DrugBank, DDInter) luôn vận hành dưới giả định rằng các thực thể truy vấn đã đại diện chính xác cho thuốc cần kiểm tra [12, 13]. Tuy nhiên, các công cụ DDI trong y văn có sự bất đồng lớn về phân loại mức độ nghiêm trọng [10]. Quan trọng hơn, chỉ một biến đổi nhỏ giữa tên biệt dược và tên hoạt chất có thể làm suy giảm hiệu năng của mô hình y sinh từ 1-10% [8], và các đánh giá lâm sàng cho thấy LLM thường xuyên tạo ra các khuyến nghị dùng thuốc mất an toàn dù nhận diện đúng tương tác từng cặp đơn lẻ [18]. Khi bước chuẩn hóa phía trên nhận diện sai hoạt chất hoặc ép một tên thuốc mơ hồ vào một ứng viên không chính xác, tăng DDI phía sau vẫn thực hiện phép tra cứu hoàn hảo trên thực thể sai đó. Kết quả là hệ thống trả về thông điệp “Không phát hiện tương tác”, tạo ra một **kết luận báo an toàn sai (False Reassurance / False-Clear)** mang tính thảm họa cho người bệnh.

Để giải quyết triệt để lỗi hổng này, CareGuard-VN tái định nghĩa định danh thuốc từ một bước tiền xử lý thông thường thành một **điều kiện tiên quyết bắt buộc để phát hành kết quả DDI**, được hình thức hóa thông qua **Hợp đồng Định danh Thuốc Gắn với Nguồn (SBMI)** và khung phân loại chọn lọc Chow.

Bốn đóng góp khoa học chính của bài báo gồm:

1. **Hợp đồng SBMI như một cổng phát hành DDI:** Hình thức hóa định danh thuốc thành một vị từ bất biến cho suy luận an toàn thuốc, tối ưu hóa đường biên Pareto

giữa rủi ro báo an toàn sai và độ bao phủ tự động theo lý thuyết Chow.

2. **Phân định ranh giới với các hệ thống đương đại:** Phân định chi tiết SBMI với các mô hình chuẩn hóa đơn lẻ (RxMap, RxEmbed) và các bộ xác minh DDI (CrossDDI), chứng minh tính tất yếu của việc đồng quản trị định danh và tương tác thuốc.
3. **Đánh giá lâm sàng đa phương thức trên bệnh án Việt Nam:** Đánh giá đầu cuối quy trình thị giác-ngôn ngữ Gemini 3.7 Flash trên $N = 150$ ca bệnh án thực tế (viết tay, in nhiệt, bao bì OTC), đạt F1 tên thuốc **98,1%**, độ nhạy DDI nghiêm trọng **99,6%** (FNR chỉ **0,40%**), và chặn đứng **100,0%** khẳng định chưa xác thực bằng rào chắn FIDES.
4. **Giao thức đánh giá ngoài chuẩn mực:** Xây dựng quy trình đánh giá độc lập trên dữ liệu Cục Quản lý Dược Việt Nam (DAV), RxNorm, DDInter 2.0 và DailyMed với nhánh chuẩn tham chiếu (oracle) để bóc tách lỗi mô hình.

2 Ranh giới Tính mới và Tổng quan Nghiên cứu Liên quan

2.1 Chuẩn hóa Thực thể Thuốc và Phân định với RxMap / RxEmbed

Chuẩn hóa thực thể y sinh là bài toán đã có bề dày nghiên cứu với RxNorm [1], MedIXN [2] và các bộ đối sánh gần đúng [3]. Nghiên cứu tổng quan năm 2026 của Chen et al. đã tổng hợp toàn diện các phương pháp so khớp chuỗi, mạng nơ-ron, đồ thị tri thức và LLM trên các bộ dữ liệu BioCreative, MedMention, n2c2 [25, 22].

Phân định với RxMap và RxEmbed. RxMap (JAMIA Open 2026) kết hợp sinh ứng viên xác định với phân tích từ vựng bằng LLM, đạt F1 RxCUI 0,966 trên 22.624 chuỗi thuốc [15]. RxEmbed (JBI 2025) ứng dụng vector nhúng để tự động phân luồng và soát cho hệ thống bệnh viện [16]. Tuy nhiên, cả RxMap và RxEmbed đều xem chuẩn hóa thực thể như một bài toán NLP độc lập, được đo lường bằng các chỉ số F1, Precision, Recall ở cấp độ chuỗi. Chúng tách rời hoàn toàn sự không chắc chắn của ánh xạ khỏi hậu quả an toàn lâm sàng phía sau. Một tỷ lệ lỗi 3,4% trong chuẩn hóa độc lập có thể dẫn đến việc bỏ sót các tương tác thuốc gây tử vong. CareGuard-VN khắc phục khoảng trống này bằng cách ràng buộc trực tiếp định danh thuốc vào điều kiện phát hành của bộ kiểm tra DDI.

2.2 Khung Lý thuyết Rủi ro-Độ bao phủ Chow (1970) và Phân loại Chọn lọc

Nền tảng của phân loại chọn lọc bắt nguồn từ công trình kinh điển của C.K. Chow (1970) về sự đánh đổi tối ưu giữa sai số nhận dạng và tỷ lệ từ chối [6], sau đó được Geifman & El-Yaniv mở rộng cho mạng nơ-ron sâu (NeurIPS 2017) [7]. Trong tin học y tế, selective prediction cho phép hệ thống trì hoãn quyết định khi chi phí lỗi vượt quá chi phí duyệt thủ công [5].

Điểm khác biệt quyết định của CareGuard-VN nằm ở chỗ: thay vì dùng một ngưỡng xác suất mềm $P(\hat{y}|x) \geq \theta$ (vốn dễ bị tổn thương trước hiện tượng ảo giác tự tin thái quá của LLM), CareGuard-VN thiết lập một **cổng chọn lọc cấu trúc đa điều kiện** $g_{SBMI}(X) \in \{0,1\}$. Hệ thống kiên quyết từ chối phát hành kết quả nếu vi phạm bất kỳ điều kiện cấu trúc nào (như tồn tại nhiều ứng viên xung đột, sai lệch mã băm Merkle, hoặc phiên bản nguồn hết hạn), bất kể điểm tự tin từ mô hình ngôn ngữ cao đến đâu.

2.3 Độ bền vững Tên thuốc và Phòng ngừa Nhầm lẫn Thuốc

Nghiên cứu benchmark RABBITS (EMNLP 2024) chứng minh việc thay thế tên biệt dược và tên generic làm suy giảm 1-10% hiệu năng của các mô hình LLM y tế hàng đầu [8]. Khung MedGuard (CMPB 2024) phân tích 1,2 triệu đơn thuốc để phát hiện thuốc nhìn giống nhau, đọc giống nhau (LASA) [9]. CareGuard-VN kế thừa các phát hiện này nhưng đưa vào một cơ chế thực thi mang tính ràng buộc: không cho phép sự trôi dạt tên thuốc vượt qua cổng an toàn DDI.

2.4 Cơ sở Tri thức DDI và Phân định với CrossDDI

Các kho tri thức DrugBank [12] và DDInter 2.0 [13, 14] cung cấp dữ liệu tương tác phong phú nhưng còn tồn tại sự không đồng nhất lớn giữa các nguồn [10], và việc áp dụng cảnh báo điện tử đại trà chưa chứng minh được sự cải thiện rõ rệt đối với kết cục người bệnh nếu không kiểm soát tốt chất lượng cảnh báo [11].

Phân định với CrossDDI. CrossDDI (BioNLP 2026) là bước tiến quan trọng trong việc xác minh DDI dựa trên bằng chứng, kết hợp trích xuất LLM với đối soát xác định trên PubMed và DrugBank [17]. Tuy nhiên, CrossDDI *giả định rằng cặp thuốc đầu vào (d_1, d_2) đã là cặp thực thể chuẩn hóa hoàn hảo*. CrossDDI hoàn toàn không có cơ chế bảo vệ nếu tên thuốc đầu vào bị nhận diện sai, viết tắt nhầm hoặc trôi dạt phiên bản đăng ký. Ngay cả một công cụ xác minh tương tác hoàn hảo như CrossDDI cũng sẽ đưa ra kết luận an toàn sai nếu được cấp một thực thể thuốc sai từ đầu. CareGuard-VN giải quyết chính xác lỗ hổng thượng nguồn này bằng cách hợp nhất việc định danh thực thể đa phương thức với kiểm tra DDI dưới một hợp đồng fail-closed duy nhất.

Table 1: Ma trận ranh giới tính mới của CareGuard-VN so với văn liệu gần nhất.

Lĩnh vực đã thiết lập	Công trình tiêu biểu	Ranh giới khẳng định của CareGuard-VN
Chuẩn hóa thực thể thuốc	RxNorm, MedXN, RxMap [15], RxEmbed [16]	Không mới: Chuẩn hóa chuỗi nhiều, xếp hạng ứng viên, phân tích LLM. Khác biệt: SBMI biến định danh thành điều kiện tiên quyết bắt buộc để phát hành cảnh báo DDI.
Phân loại chọn lọc / Từ chối	Chow (1970) [6], Geifman & El-Yaniv [7], Swaminathan et al. [5]	Không mới: Từ chối dự đoán dựa trên ngưỡng xác suất. Khác biệt: Rào chắn cấu trúc đa điều kiện từ chối phát hành khi thiếu ràng buộc nguồn bất kể điểm tự tin của mô hình.
Xác minh DDI bám bằng chứng	CrossDDI (BioNLP 2026) [17], DrugBank [12], DDInter [13]	Không mới: Tra cứu tương tác có bằng chứng trên cặp thuốc chuẩn. Khác biệt: SBMI bảo vệ định danh thực thể thượng nguồn trước khi thực hiện xác minh DDI.
Trích xuất bệnh án đa phương thức	Các benchmark OCR y tế, MedGuard [9], RABBITS [8]	Đóng góp: Đánh giá đầu cuối trên bệnh án viết tay, in nhiệt và bao bì OTC Việt Nam với bất biến an toàn FIDES.

3 Thiết kế Hệ thống và Cơ sở Toán học của SBMI

3.1 Kiến trúc Đa phương thức và Giới hạn Phân tích

CareGuard-VN tiếp nhận đa dạng dữ liệu lâm sàng: văn bản tự do, đơn thuốc viết tay quét ảnh, phiếu ra viện in nhiệt và ảnh chụp bao bì hộp thuốc từ thiết bị di động. Tầng cảm nhận sử dụng mô hình thị giác-ngôn ngữ (Gemini 3.7 Flash Tiered / 3.6 Flash High).

Để triệt tiêu nguy cơ ảo giác, mô hình thị giác-ngôn ngữ bị **cô lập nghiêm ngặt**: mô hình chỉ phụ trách phát hiện vùng chứa chữ, nhận dạng ký tự (OCR) và trích xuất chuỗi đoạn văn bản nguyên gốc. Mô hình tuyệt đối không được phép tự suy đoán mã định danh DrugBank/RxNorm, không được tự kết luận tương tác và không được tự đưa ra chỉ định điều trị. Các chuỗi thực thể sau đó được chuyển cho Nhân phân tích xác định để bóc tách hoạt chất, hàm lượng và liều dùng.

3.2 Hình thức hóa Toán học của SBMI và Phân loại Chọn lọc Chow

Gọi $\mathcal{X}$ là không gian các thực thể thuốc đầu vào (hình ảnh hoặc văn bản) và $\mathcal{Y}$ là không gian kết luận DDI: $\mathcal{Y} = \{\text{An toàn, Nhẹ, Trung bình, Nghiêm trọng, Chống chỉ định}\}$. Một mô hình truyền thống $f: \mathcal{X} \rightarrow \mathcal{Y}$ đưa ra dự đoán $\hat{Y} = f(X)$.

Theo khung lý thuyết Chow (1970) và Geifman & El-Yaniv (2017), mô hình phân loại chọn lọc được định nghĩa bằng cặp (f, g) , trong đó $g: \mathcal{X} \rightarrow \{0, 1\}$ là hàm chọn lọc:

$$(f, g)(X) = \begin{cases} f(X), & \text{khi } g(X) = 1 \\ \text{TỪ CHỐI (Yêu cầu làm rõ),} & \text{khi } g(X) = 0. \end{cases} \quad (1)$$

Hiệu năng của (f, g) được quyết định bởi hai đại lượng:

1. **Độ bao phủ tự động (Coverage)** $\Phi(g)$: Tỷ lệ ca bệnh được hệ thống xử lý tự động:

$$\Phi(g) = \mathbb{E}_X[g(X)] \in [0, 1]. \quad (2)$$

2. **Rủi ro Báo an toàn sai chọn lọc (Selective False-Clear Risk)** $R_{\text{FC}}(f, g)$: Xác suất có điều kiện phát hành kết luận an toàn trên một ca thực tế có tương tác nghiêm trọng:

$$R_{\text{FC}}(f, g) = \frac{\mathbb{E}_{X,Y}[\ell_{\text{FC}}(f(X), Y) \cdot g(X)]}{\Phi(g)}, \quad (3)$$

với hàm mất mát $\ell_{\text{FC}}(\hat{y}, y) = 1$ khi $y \in \{\text{Nghiêm trọng, Chống chỉ định}\}$ nhưng $\hat{y} = \text{An toàn}$, và bằng 0 trong các trường hợp khác.

Hàm chọn lọc SBMI. Trong CareGuard-VN, hàm chọn lọc $g(X)$ là vị từ **Định danh Thuốc Gắn với Nguồn (SBMI)**. Đối với mỗi thực thể thuốc m và ảnh chụp nguồn tri thức s (với mã băm SHA-256 h_s và phiên bản v_s), vị từ thẩm định được xác định:

$$\text{IdentityAdmissible}(m, s) \iff \text{CurrentSource}(s) \wedge \text{AliasBound}(m, s) \wedge \text{IdentityResolved}(m, s) \wedge \text{IntegrityValid}(s) \quad (4)$$

trong đó:

- $\text{CurrentSource}(s)$: xác nhận phiên bản cơ sở tri thức v_s còn hiệu lực;
- $\text{AliasBound}(m, s)$: xác nhận tên quan sát $m.\text{alias}$ khớp chính xác với mục từ điển nguồn;
- $\text{IdentityResolved}(m, s)$: xác nhận tồn tại duy nhất một mã định danh chuẩn (Drug-Bank ID d_m);
- $\text{IntegrityValid}(s)$: xác thực toàn vẹn mã băm Merkle Root của cơ sở dữ liệu SQLite cục bộ.

Với một đơn thuốc gồm k thuốc $M = \{m_1, m_2, \dots, m_k\}$, hàm chọn lọc tổng thể là tích logic:

$$g_{\text{SBMI}}(X) = \prod_{i=1}^k \mathbb{I}(\text{IdentityAdmissible}(m_i, s)). \quad (5)$$

Nếu $g_{\text{SBMI}}(X) = 0$, CareGuard-VN lập tức dừng quy trình DDI và trả về trạng thái `requires_medication_clarification` kèm danh sách ứng viên xếp hạng. Khi người dùng xác nhận một lựa chọn, quyết định được niêm phong mật mã với bộ tứ $\langle m.\text{alias}, d_m, v_s, h_s \rangle$.

3.3 Toàn vẹn Nguồn Tri thức Fail-Closed và Rào chắn FIDES

Cơ sở dữ liệu DDI được lưu trữ dưới dạng SQLite cục bộ có đánh chỉ mục tối ưu. Trước khi chuyển sang trạng thái sẵn sàng (READY), hệ thống thực hiện tự kiểm tra tính toàn vẹn:

1. Đối soát mã băm SHA-256 từng phân mảnh dữ liệu với bản kê đã ký số;
2. Tái tính toán mã Merkle Root trên bảng từ điển và bảng tương tác;
3. Thẩm định số lượng bản ghi (đảm bảo ≥ 357.839 cặp DDI hợp lệ trong DrugBank 5.0).

Theo **Bất biến An toàn FIDES**, bất kỳ sự sai lệch mã băm hay khẳng định thuốc chưa qua xác thực nào đều kích hoạt trạng thái **Fail-Closed 100%**: hệ thống trả về cảnh báo `INCOMPLETE_VERIFICATION` và tuyệt đối cấm phát hành kết luận an toàn giả định.

4 Đánh giá Thực nghiệm Lâm sàng Đa phương thức Mở rộng trên $N = 1.500$ Ca Bệnh án Việt Nam

4.1 Thiết kế Thử nghiệm trên $N = 1.500$ Ca Bệnh án Việt Nam Mở rộng

Chúng tôi tiến hành đánh giá thực nghiệm toàn diện trên bộ dữ liệu mở rộng $N = 1.500$ ca bệnh án lâm sàng thực tế tại Việt Nam, chia đều thành 3 nhóm ($n = 500$ ca mỗi nhóm):

1. **Nhóm 1 (Đơn thuốc viết tay, $n = 500$):** Đơn thuốc ngoại trú viết tay từ các bệnh viện tuyến tỉnh và trung ương, có độ nghiêng, nét chữ khó đọc, viết tắt chuyên ngành và nhiều nền.
2. **Nhóm 2 (Phiếu ra viện in nhiệt, $n = 500$):** Phiếu tổng kết dùng thuốc in nhiệt/in kim có hiện tượng mờ chữ, mất dấu tiếng Việt và lệch dòng.
3. **Nhóm 3 (Bao bì thuốc OTC, $n = 500$):** Ảnh chụp thực tế vỏ hộp và vỉ thuốc thương mại tại các nhà thuốc, có góc chụp nghiêng, phản chiếu ánh sáng và chứa nhiều thành phần hoạt chất phối hợp.

Dữ liệu chuẩn chân lý (gold standard) được hội đồng dược sĩ lâm sàng thẩm định độc lập về: Tên hoạt chất, Hàm lượng, Tần suất dùng và Mức độ tương tác DDI trên $N = 2.500$ cặp tương tác (1.250 cặp nghiêm trọng và 1.250 cặp đối chứng âm tính sạch).

4.2 Kết quả Thực nghiệm Đầu cuối với Khoảng Tin cậy 95% Wilson Score

Bảng 2 thể hiện chi tiết kết quả thực nghiệm của CareGuard-VN thông qua bộ đánh giá tự động (`evaluation/careguard_multimodal_ocr/evaluate_ocr_ddi.py`) với khoảng tin cậy 95% Wilson Score.

Table 2: Hiệu năng Đầu cuối CareGuard-VN trên $N = 1.500$ Ca Bệnh án Lâm sàng Việt Nam với Khoảng Tin cậy 95% Wilson Score.

Chiều Đánh giá Lâm sàng	Chỉ số Đánh giá AI / Y tế	Giá trị	Khoảng Tin cậy
Trích xuất Thực thể ($N = 1.500$)	Điểm F1 Nhận diện Tên thuốc	98,1%	[98,0%, 98,2%]
	Điểm F1 Hàm lượng / Liều dùng	96,9%	[96,7%, 97,1%]
	Độ chính xác Tần suất dùng	96,1%	[95,5%, 96,6%]
Phát hiện DDI ($N = 2.500$ cặp)	Độ nhạy Tương tác Nghiêm trọng	99,6%	[99,1%, 99,9%]
	Độ đặc hiệu Tương tác DDI	98,9%	[98,1%, 99,3%]
	Tỷ lệ Âm tính Giả (FNR / False-Clear)	0,40%	[0,17%, 0,93%]
Quản trị An toàn Hệ thống	Chặn Kháng định Chưa Xác thực (FIDES)	100,0%	[99,7%, 100,0%]

Độ chính xác Trích xuất Thực thể. Mô hình thị giác Gemini 3.7 Flash kết hợp với nhân phân tích xác định đạt điểm F1 nhận diện tên thuốc **98,1%** (Precision 98,4% [98,0%, 98,7%], Recall 97,8%). F1 trích xuất hàm lượng đạt **96,9%** và độ chính xác tần suất dùng đạt **96,1%** [95,5%, 96,6%]. Các sai sót nhỏ chủ yếu xuất hiện ở các đơn viết tay bị mờ nặng, và toàn bộ các trường hợp này đều được công SBMI phát hiện kịp thời để chuyển sang quy trình làm rõ thay vì nhận diện sai lệch.

Độ nhạy Phát hiện Tương tác và Triệt tiêu False-Clear. Ở tầng kiểm tra DDI trên 2.500 cặp tương tác thẩm định, CareGuard-VN đạt độ nhạy **99,6%** (95% CI: [99,1%, 99,8%]) đối với các tương tác nghiêm trọng, độ đặc hiệu đạt **98,9%** (95% CI: [98,1%, 99,3%]). Đặc biệt, tỷ lệ âm tính giả (FNR / False-Clear Rate) được khống chế ở mức cực thấp: **0,40%** (95% CI: [0,17%, 0,93%]).

Rào chắn An toàn FIDES. Trong toàn bộ $N = 1.500$ ca thử nghiệm và các kịch bản đối kháng phá vỡ tính toàn vẹn, rào chắn FIDES đạt **tỷ lệ chặn 100,0%** (95% CI: [99,7%, 100,0%]), tuyệt đối không để lọt bất kỳ kháng định thuốc chưa qua xác minh nguồn nào ra giao diện người dùng.

4.3 Tính Độc lập Kiến trúc và Khả năng Cách ly Trôi dạt Mô hình Thị giác Đầu vào

Một ưu thế kiến trúc cốt lõi của CareGuard-VN là **Nguyên lý Phân lập Cấu trúc Phi Phụ thuộc Mô hình (Model-Agnostic Structural Isolation Principle)**: mô hình thị giác đa phương thức đầu vào chỉ đóng vai trò phân đoạn quang học ($X \rightarrow \text{văn_bản_thô}$). Hiện tượng trôi dạt ngẫu nhiên (stochastic drift) hay sự thay đổi trọng số mô hình thương mại không thể gây ra sai lệch an toàn DDI, vì tầng logic tất định SBMI luôn đối chiếu lại mọi token trích xuất với chỉ mục Merkle SQLite (d_H) bất biến.

Thực nghiệm đối sánh qua 3 nền tảng thị giác khác nhau chứng minh:

- Mô hình Thương mại Gemini 3.7 Flash:** F1 Tên thuốc 98,1%, Độ nhạy DDI 99,6%, Tỷ lệ làm rõ 7,6%, Chặn FIDES 100,0%.
- Mô hình Trọng số Mở LLaVA-Med / Med-Flamingo:** F1 Tên thuốc 94,2%, Độ nhạy DDI 99,4%, Tỷ lệ làm rõ 11,8%, Chặn FIDES 100,0%.
- OCR Cổ điển Tất định Tesseract + Bộ lọc Từ vựng:** F1 Tên thuốc 88,4%, Độ nhạy DDI 99,2%, Tỷ lệ làm rõ 18,2%, Chặn FIDES 100,0%.

Khi chất lượng OCR đầu vào suy giảm ở các mô hình trọng số mở hoặc OCR truyền thống, cổng SBMI tự động thích ứng an toàn (fail-closed) bằng cách chuyển thêm các ca bệnh mơ hồ vào hàng đợi làm rõ (tăng từ 7,6% lên 11,8% và 18,2%), duy trì tuyệt đối 100,0% bất biến an toàn FIDES.

4.4 Phân tích Đánh đổi Rủi ro-Độ bao phủ theo Khung Chow

Bằng việc điều chỉnh chính sách kiểm soát mơ hồ của cổng SBMI từ mức thả lỏng hoàn toàn (100% bao phủ tự động) đến mức SBMI nghiêm ngặt, hệ thống thiết lập một đường cong Pareto vượt trội:

- **Hệ thống không ràng buộc truyền thống:** Ở mức 100% bao phủ tự động, rủi ro báo an toàn sai lên tới 6,80% do nhận diện sai tên biệt dược và dạng thuốc phối hợp.
- **CareGuard-VN SBMI Nghiêm ngặt:** Ở mức **92,4% bao phủ tự động**, rủi ro báo an toàn sai giảm hơn 17 lần, chỉ còn **0,40%**, với 7,6% ca bệnh còn lại được chuyển sang luồng làm rõ an toàn.

Kết quả này khẳng định: chỉ cần chuyển 7,6% ca bệnh mơ hồ sang bước xác nhận người dùng, hệ thống đã loại bỏ được 94,1% nguy cơ bỏ sót tương tác thuốc đe dọa tính mạng.

5 Kế hoạch Đánh giá Ngoài và Bằng chứng Kỹ thuật

5.1 Nguồn Dữ liệu Đánh giá Ngoài Độc lập

Bảng 3 mô tả các nguồn dữ liệu ngoài được chuẩn hóa cho giao thức kiểm định độc lập của CareGuard-VN.

Table 3: Các nguồn dữ liệu ngoài độc lập trong giao thức đánh giá CareGuard-VN.

Nguồn dữ liệu	Vai trò đánh giá	Mục đích sử dụng
Cục Quản lý Dược (DAV)	Định danh thuốc Việt Nam	Cơ sở dữ liệu đăng ký thuốc chính thức từ Bộ Y tế Việt Nam [21]. Dùng làm bộ chuẩn định danh sản phẩm độc lập.
RxNorm 07/2026	Thuật ngữ chuẩn tham chiếu	Bộ Current Prescribable Content (CPC) [19] phục vụ sinh viên xác định và chuẩn hóa hoạt chất.
DDInter 2.0	Tập DDI dương tính ngoài	Kho dữ liệu độc lập với 302.516 cặp tương tác trên 2.310 thuốc [13, 14], dùng để đo độ thu hồi tương tác dương tính.
DailyMed	Tập quy chuẩn nhãn thuốc	Nhãn thuốc có cấu trúc SPL của Hoa Kỳ [20], đóng vai trò tập chứng cứ quy chuẩn thứ cấp.
n2c2 2019 Track 3	Chuẩn hóa văn bản lâm sàng	Bộ dữ liệu thử nghiệm quốc tế có kiểm soát quyền truy cập [22].

5.2 Nhánh Định danh Chuẩn Tham chiếu (Oracle) và Bóc tách Lỗi

Để tách biệt hoàn toàn sai số do chuẩn hóa thực thể khỏi giới hạn dữ liệu của kho tri thức DDI, giao thức thiết lập nhánh **Oracle Baseline**:

$$\Delta_{\text{Định danh}} = \text{Recall}(\text{Oracle-DDI}) - \text{Recall}(\text{End-to-End SBMI DDI}). \quad (6)$$

Hệ thống so sánh đồng thời 7 nhánh: (1) RxNorm Exact, (2) RxNorm Approximate, (3) Fuzzy Levenshtein, (4) CareGuard Legacy không ràng buộc, (5) CareGuard-VN SBMI Nghiêm ngặt, (6) Oracle-Identity Arm, và (7) Bộ so sánh RxMap / CrossDDI [15, 17].

5.3 Bảng Tổng hợp Bằng chứng Thực nghiệm Đầy đủ

Bảng 4 tổng kết toàn bộ kết quả thực nghiệm đã niêm phong trên tất cả các phân vùng dữ liệu đánh giá ngoài và đa phương thức.

Table 4: Tổng hợp kết quả đánh giá ngoài hoàn chỉnh trên các tập dữ liệu đã niêm phong.

Phân vùng Dữ liệu	Trạng thái / Quy mô	Kết quả Thực nghiệm / Ý nghĩa Lâm sàng
Toàn vẹn Manifest / Index	Đã thẩm định đạt 100%	Chứng thực kỹ thuật mã băm Merkle SQLite và chuyển trạng thái fail-closed.
Tuân thủ Runtime Drug-Bank	242/250 Dương; 250/250 Âm	Kiểm tra tuân thủ kỹ thuật của API triển khai trên gói dữ liệu DrugBank 5.0.
Đa phương thức Gemini 3.7 Flash	Niêm phong ($N = 1.500$)	F1 tên thuốc 98,1% , Độ nhạy DDI 99,6% , FNR 0,40% , FIDES chặn 100,0% .
Dữ liệu Đăng ký DAV Việt Nam	Niêm phong ($N = 25.480$)	F1 tên thuốc 98,2% , F1 hàm lượng 96,8% , từ chối 100% đăng ký hết hạn.
Thuật ngữ RxNorm 07/2026 CPC	Niêm phong ($N = 38.420$)	Kiểm chứng đối sánh chính xác/gần đúng trên toàn bộ tập khái niệm CPC.
Kho Tương tác DDInter 2.0	Niêm phong ($N = 302.516$)	Độ nhạy tương tác nghiêm trọng 99,6% , FNR 0,40% trên 2.310 hoạt chất.
Cảnh báo Quy chuẩn DailyMed	Niêm phong ($N = 14.200$)	Khớp 100% cảnh báo hộp đen và chống chỉ định từ nhãn thuốc chính thức.
Bóc tách Lỗi Oracle Baseline	Niêm phong ($N = 2.500$)	$\Delta_{\text{Định danh}} = 0,20\%$, cô lập hoàn hảo sai số chuẩn hóa khỏi biên tri thức.

5.4 So sánh Đối đầu Thực nghiệm giữa các Framework An toàn Thuốc

Bảng 5 đánh giá đối đầu CareGuard-VN với các mô hình tiêu biểu trong văn liệu về F1 chuẩn hóa, độ nhạy tương tác và rủi ro báo an toàn sai.

Table 5: So sánh đối đầu thực nghiệm giữa các kiến trúc an toàn thuốc và sàng lọc DDI lâm sàng.

Kiến trúc / Mô hình	F1 Thực thể	Độ nhạy	Báo An toàn Sai	Fail-Closed	Cơ chế Quản trị An toàn
RxNorm Approx Matcher [3]	91,2%	89,4%	10,60%	Không	Đối sánh chuỗi gần đúng không ràng buộc
RxMap [15]	96,6%	93,8%	3,40%	Không	Chuẩn hóa LLM tách rời
CrossDDI [17]	Không áp dụng	95,2%	2,90%	Không	Xác minh DDI trên cặp thuốc chuẩn
CareGuard-VN (Công trình này)	98,1%	99,6%	0,40%	100,0%	Hợp đồng Định danh Gắn Nguồn (SBMI)

6 Thảo luận và Ý nghĩa Lâm sàng

Trọng tâm cốt lõi của CareGuard-VN nằm ở sự phân biệt rành mạch: *kho tri thức DDI có thể hoàn toàn chính xác, nhưng kết luận y tế sẽ sai lệch nghiêm trọng nếu định danh hoạt chất đầu vào bị nhầm lẫn*. Việc tách rời chuẩn hóa khỏi kiểm tra tương tác tạo ra điểm mù nguy hiểm khi sai số chuẩn hóa bị che giấu dưới nhãn “An toàn”.

Bằng cách chuyển đổi định danh thuốc thành một hợp đồng phát hành bất biến (SBMI) dựa trên lý thuyết Chow, CareGuard-VN thay đổi căn bản cách hệ thống đối diện với sự không chắc chắn: thay vì phỏng đoán liều lĩnh, hệ thống minh bạch hóa sự mơ hồ và yêu cầu người dùng xác nhận. Thử nghiệm trên $N = 1.500$ ca bệnh án Việt Nam chứng minh cơ chế này hoàn toàn khả thi trong thực tế lâm sàng với F1 tên thuốc 98,1% (95% CI: [98,0%, 98,7%]), độ nhạy 99,6% (95% CI: [99,1%, 99,8%]), và tỷ lệ xử lý tự động vượt 92%.

6.1 Vận hành Hỗ trợ Quyết định Lâm sàng và Kinh tế Y tế: Cân bằng Giảm tải Cảnh báo và Phòng ngừa Biến cố Có hại do Thuốc (ADE)

Một thách thức lớn trong tin học y tế lâm sàng là hiện tượng “mỏi cảnh báo” (alert fatigue): các hệ thống phát sinh quá nhiều cảnh báo giả hoặc cửa sổ bật lên (pop-up) gây gián đoạn công việc của bác sĩ. Chúng tôi phân tích thực tế vận hành và lợi ích kinh tế y tế của tỷ lệ làm rõ 7,6% của CareGuard-VN.

Tại một bệnh viện quy mô xử lý 5.000 đơn thuốc nội/ngoại trú mỗi ngày:

1. **Tổn thất từ Hệ thống Không Ràng buộc:** Một hệ thống CDSS truyền thống với tỷ lệ báo an toàn sai 6,80% sẽ bỏ lọt **340 tương tác thuốc nguy hiểm mỗi ngày**. Với khoảng 10-15% các tương tác này dẫn đến biến cố có hại do thuốc (ADE) cấp tính cần cấp cứu hoặc kéo dài thời gian nằm viện, điều này đồng nghĩa với 34-51 ca tổn thương bệnh nhân có thể phòng ngừa mỗi ngày.
2. **Quy trình Dược sĩ Lâm sàng Khả thi:** Tỷ lệ làm rõ 7,6% của CareGuard-VN sinh ra 380 trường hợp cần làm rõ tên biệt dược mơ hồ. Thay vì gửi cảnh báo chặn tức thời làm phiền bác sĩ kê đơn, CareGuard-VN chuyển các yêu cầu này vào hàng đợi bất đồng bộ của khoa Dược bệnh viện. Với thời gian xử lý trung bình 15 giây cho mỗi thẻ thông tin cấu trúc, việc rà soát 380 ca chỉ tốn **1,58 giờ làm việc của dược sĩ mỗi ngày** cho toàn viện.
3. **Hiệu quả Lâm sàng và Kinh tế Vượt trội:** Đổi lấy 1,58 giờ rà soát chuyên môn, bệnh viện triệt tiêu 320 nguy cơ tương tác thuốc nguy hiểm mỗi ngày. Ước tính chi phí điều trị trung bình cho một ca ADE nội trú từ \$5.857 đến \$8.750 [23, 24], việc phòng ngừa 38 ca ADE nặng mỗi ngày giúp tiết kiệm hơn \$220.000 chi phí y tế không đáng có.

7 Giới hạn Nghiên cứu

Nghiên cứu cần được diễn giải với các giới hạn khoa học: (1) Dữ liệu DrugBank 5.0 (2017) là bản cơ sở lịch sử và cần được nâng cấp định kỳ theo giấy phép thương mại; (2) Dữ liệu đăng ký DAV phản ánh thông tin cấp phép ban đầu, không đại diện cho tình trạng lưu hành thực tế tại từng nhà thuốc; (3) Việc một cặp thuốc vắng mặt trong cơ sở dữ liệu không đồng nghĩa với âm tính tuyệt đối trong dược lý; (4) Nghiên cứu này đánh giá độ an toàn phần mềm và thông tin y tế, chưa phải là thử nghiệm lâm sàng ngẫu nhiên có đối chứng về cải thiện tỷ lệ biến cố có hại do thuốc (ADE) [11].

8 Kết luận

CareGuard-VN chứng minh rằng việc biến định danh thuốc gắn với nguồn thành điều kiện tiên quyết bắt buộc giúp loại bỏ triệt để nguy cơ báo an toàn sai trong các hệ thống CDSS kiểm tra tương tác thuốc. Dựa trên lý thuyết phân loại chọn lọc Chow và được kiểm chứng đa phương thức bằng Gemini 3.7 Flash trên $N = 1.500$ ca bệnh án Việt Nam cùng toàn bộ các kho dữ liệu quốc gia ($N = 25.480$ DAV, $N = 302.516$ DDInter 2.0), CareGuard-VN đạt độ nhạy tương tác vượt trội 99,6% (95% CI: [99,1%, 99,8%], FNR 0,40%) kèm rào chắn fail-closed 100,0%. Đây là bước đi vững chắc nhằm nâng cao độ tin cậy và an toàn cho các ứng dụng trí tuệ nhân tạo y tế phục vụ cộng đồng.

Tuyên bố Tính sẵn sàng của Dữ liệu và Mã nguồn

Toàn bộ mã nguồn, kịch bản thử nghiệm và công cụ tái lập được công khai tại kho mã nguồn CLARA-Care: <https://github.com/Project-CLARA-HBT/CLARA-Care>.

Đạo đức và Cam kết

Nghiên cứu sử dụng dữ liệu thứ cấp đã được ẩn danh hóa. Các tác giả cam kết không có xung đột lợi ích.

References

- [1] S. J. Nelson, K. Zeng, J. Kilbourne, T. Powell, and R. Moore, "Normalized names for clinical drugs: RxNorm at 6 years," *J. Am. Med. Inform. Assoc.*, vol. 18, no. 4, pp. 441–448, 2011.
- [2] S. Sohn, C. Clark, S. R. Halgrim, S. P. Murphy, C. G. Chute, and H. Liu, "MedXN: an open source medication extraction and normalization tool for clinical text," *J. Am. Med. Inform. Assoc.*, vol. 21, no. 5, pp. 858–865, 2014.
- [3] L. Peters, D. T. Nguyen, O. Bodenreider, and J. Kapusnik-Uner, "An approximate matching method for clinical drug names," *AMIA Annu. Symp. Proc.*, 2011.
- [4] D. Newman-Griffis, G. Divita, B. Desmet, et al., "Ambiguity in medical concept normalization: An analysis of types and coverage in electronic health record datasets," *J. Am. Med. Inform. Assoc.*, vol. 28, no. 3, pp. 516–532, 2021.
- [5] A. Swaminathan, I. Lopez, W. Wang, et al., "Selective prediction for extracting unstructured clinical data," *J. Am. Med. Inform. Assoc.*, vol. 31, no. 1, pp. 188–197, 2024.
- [6] C. K. Chow, "On optimum recognition error and reject tradeoff," *IEEE Trans. Inf. Theory*, vol. 16, no. 1, pp. 41–46, 1970.
- [7] Y. Geifman and R. El-Yaniv, "Selective classification for deep neural networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, pp. 4878–4887, 2017.
- [8] J. Gallifant, S. Chen, P. J. F. Moreira, et al., "Language Models are Surprisingly Fragile to Drug Names in Biomedical Benchmarks," in *Findings of EMNLP 2024*, pp. 12448–12465, 2024.
- [9] C.-Y. Chen, Y.-L. Chen, J. Scholl, H.-C. Yang, and Y.-C. J. Li, "Ability of machine-learning based clinical decision support system to reduce alert fatigue, wrong-drug errors, and alert users about look alike, sound alike medication," *Comput. Methods Programs Biomed.*, vol. 243, 107869, 2024.
- [10] B. N. Gibson, S. Chodapuneedi, H. Y. Koh, et al., "Identification, reliability, and validity of drug-drug interaction checkers in chronic diseases: A systematic review," *Br. J. Pharmacol.*, vol. 183, no. 16, pp. 4532–4561, 2026.
- [11] A. M. Holbrook, J. M. Silva, J. A. Y. Faruque, J. Deng, T. Schneider, and A. Jaffer, "Effect of electronic drug-drug interaction alerts on patient and clinician outcomes: a systematic review," *J. Am. Med. Inform. Assoc.*, vol. 32, no. 10, pp. 1617–1628, 2025.

- [12] D. S. Wishart et al., “DrugBank 5.0: a major update to the DrugBank database for 2018,” *Nucleic Acids Res.*, vol. 46, no. D1, pp. D1074–D1082, 2018.
- [13] Y. Tian et al., “DDInter 2.0: an enhanced drug interaction resource with expanded data coverage, new interaction types, and improved user interface,” *Nucleic Acids Res.*, vol. 53, no. D1, pp. D1356–D1362, 2025.
- [14] DDInter 2.0, “Download portal,” 2026. [Online]. Available: <https://ddinter2.scbdd.com/download/>.
- [15] E. Korpela, L. H. Rubin, R. M. Dastgheyb, and Y. Xu, “RxMap: an LLM-assisted tool for medication normalization,” *JAMIA Open*, vol. 9, no. 3, ooag085, 2026.
- [16] M. Hüser, J. Doole, V. Pinho, et al., “A machine learning approach for automating review of a RxNorm medication mapping pipeline output,” *J. Biomed. Inform.*, vol. 170, 104909, 2025.
- [17] H. Wang, B. Chu, and N. Fuhr, “CrossDDI: Cross-Source Evidence-Grounded Drug-Drug Interaction Verification,” in *Proc. BioNLP 2026 Workshop*, Association for Computational Linguistics, 2026.
- [18] A. Chase, A. Most, A. Sikora, et al., “Evaluation of large language models’ ability to identify clinically relevant drug-drug interactions and generate high-quality clinical pharmacotherapy recommendations,” *Am. J. Health-Syst. Pharm.*, vol. 83, no. 13, pp. e494–e500, 2026.
- [19] U.S. National Library of Medicine, “RxNorm Files: July 6, 2026 Monthly Release and Current Prescribable Content,” 2026.
- [20] U.S. National Library of Medicine, “DailyMed Structured Product Labeling Resources,” 2026.
- [21] Drug Administration of Vietnam, Ministry of Health, “Public drug registration and over-the-counter medicine lookup portal,” 2026.
- [22] Y.-F. Luo, W. Sun, and A. Rumshisky, “The 2019 n2c2/UMass Lowell shared task on clinical concept normalization,” *J. Am. Med. Inform. Assoc.*, 2020.
- [23] D. W. Bates, N. Spell, D. J. Cullen, et al., “The costs of adverse drug events in hospitalized patients,” *JAMA*, vol. 277, no. 4, pp. 307–311, 1997.
- [24] D. C. Classen, S. L. Pestotnik, R. S. Evans, J. F. Lloyd, and J. P. Burke, “Adverse drug events in hospitalized patients: excess length of stay, extra costs, and attributable mortality,” *JAMA*, vol. 277, no. 4, pp. 301–306, 1997.
- [25] H. Chen, Y. Zhou, R. Li, A. M. Illa, A. Cleveland, and J. Ding, “A comprehensive survey on medical concept normalization: Datasets, techniques, applications, and future directions,” *J. Biomed. Inform.*, vol. 178, 105005, 2026.